

El catálogo no necesita crecer. Necesita reasignarse.

Diagnóstico del rendimiento del catálogo de contenidos y propuesta de reasignación del presupuesto de programación.

Informe ejecutivo · Evaluación Parcial N°1

ADY1104 Visualización de Datos · Unidad 1: Proceso de comunicación de datos y análisis de audiencias

Equipo consultor: Felipe Ángel · Daniel Vargas

Docente: Claudio Andrés González Peñaloza

Institución: Escuela de Informática y Telecomunicaciones, DUOC UC — Sede Los Lagos

Carrera: Ingeniería en Informática mención Ciencia de Datos

Base analítica: 31.991 títulos del catálogo (2010–2025); cohorte de trabajo 30.000 títulos (2010–2024).

MENSAJE ÚNICO DEL INFORME

La decisión no es cuánto contenido comprar, sino de qué tipo. Una serie capta 3,4 veces más atención que una película y con mejor nota, mientras US\$ 6,6 mil millones acumulados entre 2010 y 2024 siguen puestos en el tramo de películas de 1 a 10 millones de dólares, donde el 45,7% no recupera la inversión. Recomendamos reasignar ese tramo a series y activar los 5.088 títulos ya pagados que nadie ve, antes de autorizar una sola compra nueva.

CONCENTRACIÓN

47,5%

de la atención está en el 10% de los títulos

CATÁLOGO INVISIBLE

10,7%

3.202 títulos sin ninguna interacción

VENTAJA DEL FORMATO

×3,4

atención de una serie frente a una película

RIESGO FINANCIERO

45,7%

de las películas de 1-10 MUSD pierde dinero

1. Descripción del problema de negocio

StreamView Analytics es una plataforma internacional de streaming que decide cada año cuánto y qué contenido incorporar a su catálogo. Hoy esa decisión se toma principalmente por **volumen**: cuántos títulos se suman y a qué costo. El indicador que gobierna la conversación es el tamaño del catálogo, no su rendimiento.

El problema es que el catálogo crece sin que crezca la atención que recibe. La compañía necesita entender **dónde se produce realmente el retorno** de su inversión en contenido para sostener la retención de suscriptores y el nivel de interacción, y necesita comunicarlo a públicos con niveles de detalle muy distintos: un comité que decide en minutos y un equipo de programación que trabaja título por título.

La pregunta que este encargo responde es concreta: **si el presupuesto de contenido se mantuviera igual, ¿dónde habría que moverlo para capturar más atención y mejor satisfacción por cada dólar invertido?**

2. Objetivos del proyecto

Objetivo general. Diseñar una solución de visualización que permita a StreamView Analytics decidir la asignación del presupuesto de contenido sobre evidencia de rendimiento y no sobre volumen.

1. **Integrar** las fuentes de catálogo de películas y series en una base única, documentada y auditada, apta para reproducir el análisis sin pasos manuales.
2. **Identificar** los patrones que explican la concentración de la atención y los segmentos que rinden por sobre y por debajo de la mediana.
3. **Cuantificar** la relación entre inversión, visibilidad y satisfacción para detectar dónde el dinero no está comprando resultado.
4. **Construir** un dashboard interactivo que permita al equipo táctico explorar el diagnóstico por formato, idioma, género y año.

5. **Comunicar** el hallazgo mediante una narrativa visual que termine en recomendaciones concretas, medibles y con plazo.

3. Audiencia objetivo y propósito comunicacional

Una misma base de datos genera productos distintos según quién la use. Se definieron tres perfiles con nivel de detalle, propósito analítico y formato de salida propios.

Audiencia	Objetivo de comunicación	Propósito analítico	Nivel de detalle	Producto entregado	Decisión que habilita
Comité ejecutivo / Dirección de Contenidos	Convencer y apoyar la decisión	Prescriptivo	Bajo	Resumen ejecutivo (8 láminas) + KPIs del informe	Aprobar la reasignación del presupuesto 2026
Programación y Adquisición de Contenido	Explicar y monitorear	Diagnóstico	Medio-alto	Dashboard interactivo, pestañas 1 y 2	Elegir qué renovar, qué activar y qué podar
Finanzas de Contenido	Informar y apoyar la decisión	Descriptivo y diagnóstico	Alto	Dashboard interactivo, pestaña 3 + anexos	Validar el retorno por tramo de inversión

Propósito comunicacional del informe. Convencer al comité de que el problema es de asignación y no de tamaño, y dejar al equipo táctico una herramienta para ejecutar esa reasignación. Por eso el documento abre con la recomendación y deja la evidencia detrás: la audiencia que decide no debe reconstruir el razonamiento para entender qué se le pide.

4. Descripción de las fuentes de datos utilizadas

La organización puso a disposición dos fuentes corporativas de catálogo, que se integraron en una base única de **31.991 títulos** estrenados entre 2010 y 2025.

Archivo	Contenido	Filas	Columnas	Observación
netflix_movies_detailed_up_to_2025.csv	Películas	16.000	18	Incluye presupuesto y recaudación
netflix_tv_shows_detailed_up_to_2025.csv	Series	16.000	16	Sin capa financiera; 9 identificadores duplicados

4.1 Clave de integración y variables relevantes

Ambas fuentes comparten trece campos con la misma semántica, lo que permite apilarlas verticalmente y distinguirlas mediante la variable derivada `formato`. El identificador `show_id` sólo es único dentro de cada fuente, por lo que la clave del catálogo integrado es `formato + show_id`. La capa financiera se anexa únicamente a las películas.

Sobre esa base se construyeron las variables de negocio del proyecto: `atencion` (índice de popularidad, proxy de interés), `interacciones` (número de calificaciones emitidas), `satisfaccion` (nota media 0-10), `sin_senal` (título sin ninguna interacción), `segmento` (`formato` × bloque de idioma, la unidad sobre la que se decide el presupuesto) y `roi` (recaudación sobre presupuesto).

4.2 Auditoría de calidad y decisiones de saneamiento

control	n	cobertura
Registros integrados	31.991	100%
Películas	16.000	50.0%
Series	15.991	50.0%
Títulos sin ninguna interacción	4.560	14.3%
Títulos sin género declarado	1.079	3.4%
Títulos sin país informado	2.261	7.1%
Películas con presupuesto informado	4.847	30.3% de las películas
Películas con ROI calculable	3.540	22.1% de las películas
Cohorte 2025 (parcial, excluida de tendencias)	1.991	6.2%

Siete decisiones de saneamiento quedaron documentadas en `src/etl.py`. Las cuatro que más afectan la lectura de los resultados:

- **El 0 no es un valor, es un dato faltante.** Presupuesto y recaudación traen 0 donde el dato no fue informado (69,7% y 64,7% de las películas). Mantener ese 0 haría creer que la película no costó nada. Se convirtió a nulo.
- **Sin nota no es mala nota.** Cuando `vote_count = 0` la nota también vale 0. Esos títulos no tienen una evaluación pésima: no tienen evaluación. Se marcan como `sin_senal` y quedan fuera de todo promedio de satisfacción.
- **La muestra está balanceada por diseño.** Cada archivo trae exactamente 1.000 títulos por año entre 2010 y 2025. Por lo tanto, **ningún gráfico de este informe lee volumen en el tiempo**: sería una línea plana por construcción. Sólo se leen composiciones y tasas dentro de cada año.
- **La cohorte 2025 no es comparable.** El 68,2% de sus títulos aún no acumula interacciones. Se excluye de toda lectura de tendencia y el análisis trabaja sobre 30.000 títulos estrenados entre 2010 y 2024.

Dos columnas se descartaron por no aportar información: `rating` es copia exacta de `vote_average` (coincidencia del 100%), y `duration` está vacía en todas las películas y vale la constante «1 Seasons» en todas las series.

5. Análisis exploratorio mediante visualizaciones

5.1 La atención está concentrada




Figura 1. El 10% de los títulos concentra el 47,5% de la atención y el 1% más visto ya se lleva el 17,7%. El índice de Gini de 0,58 confirma un reparto muy desigual: la mayor parte del catálogo compite por la mitad restante.

La primera consecuencia de negocio es que el tamaño del catálogo no es una medida de salud. Sumar títulos a la cola larga no mueve la atención total; sólo aumenta el costo de licencia y el ruido en la interfaz de recomendación.

5.2 El formato es la variable que más explica el rendimiento





Figura 2. Una serie capta una atención mediana de 37,4 frente a 11,1 de una película — 3,4 veces más — y con una nota mediana de 7,2 frente a 6,4. Se usa la mediana y no el promedio porque la distribución tiene cola larga.

El formato que más rinde es también el más riesgoso: 1 de cada 5 series no llega a nadie

Catálogo invisible = títulos con cero interacciones · cohorte 2010-2024 (30.000 títulos) · 95,0% del catálogo invisible son series



La cohorte 2025 se muestra sólo como referencia: sus títulos aún no han tenido tiempo de acumular interacciones y no son comparables con los años anteriores. Fuente: catálogo Netflix hasta 2025 (movies + tv shows), 31.991 títulos · Elaboración propia — StreamView Analytics

Figura 3. La contracara: el 20,3% de las series no registra ninguna interacción, frente al 1,1% de las películas. El formato de mayor retorno es también el de mayor varianza.

Leídas juntas, ambas figuras evitan una conclusión simplista. La recomendación no es «comprar series», sino **comprar series con un filtro de riesgo**: el segmento concentra el retorno y también las pérdidas silenciosas.


	Títulos	Atención mediana	Catálogo invisible (%)	Nota mediana
Serie · Inglés	4.145	40,24	7,86	7,19
Serie · No inglés	10.855	36,36	25,03	7,30
Película · Inglés	8.985	11,93	0,16	6,26
Película · No inglés	6.015	9,96	2,41	6,60

Rendimiento por segmento de decisión, cohorte 2010-2024. Las series en idioma no inglés son el segmento más numeroso (10.855 títulos) y el de mejor nota (7,30), pero también el de mayor riesgo: 25,0% no llega a ninguna audiencia.

5.3 Hay inventario pagado que nadie ve

5.088 títulos ya pagados gustan más que la mediana y, aun así, nadie los ve

Cada punto es un título · 26.798 títulos con al menos una interacción · cohorte 2010-2024 · en azul, el cuadrante de Joyas ocultas



Se grafica una muestra aleatoria de 6.000 puntos para evitar el solapamiento; los recuentos de cada cuadrante corresponden al universo completo. Los umbrales son las medianas del propio conjunto filtrado. Fuente: catálogo Netflix hasta 2025 (movies + tv shows), 31.991 títulos · Elaboración propia — StreamView Analytics

Figura 4. Cruzando atención y satisfacción sobre sus medianas aparecen cuatro decisiones distintas. El cuadrante crítico es **Joyas ocultas**: 5.088 títulos con nota por sobre la mediana y atención por debajo. Es inventario ya pagado que no está llegando a su audiencia.

	Títulos	Atención mediana	Nota mediana	% series	% no inglés	% del catálogo con señal
Motores	8.761	41,99	7,60	83,77	60,45	32,69
Ruido	4.638	38,64	6,00	71,19	56,49	17,31
Joyas ocultas	5.088	11,65	7,20	17,37	57,86	18,99
Rezagados	8.311	9,73	5,90	5,20	37,88	31,01

5.4 El dinero está en el tramo equivocado




Figura 5. El tramo de 1 a 10 millones de dólares concentra US\$ 6,6 mil millones en 1.196 películas, con el ROI mediano más bajo (1,20) y la mayor proporción de títulos que no recuperan la inversión (45,7%). Los extremos — producciones muy baratas y grandes apuestas— rinden mejor.




Figura 6. Al pasar del decil de presupuesto más barato al más caro, la atención se multiplica por más de cinco mientras la nota se mueve apenas. La correlación de Spearman lo confirma: $\rho = 0,56$ entre presupuesto y atención, $\rho = 0,06$ entre presupuesto y satisfacción. **El presupuesto compra visibilidad, no agrado.**

5.5 Dónde está creciendo el catálogo y qué géneros rinden



Figura 7. La participación del contenido en idioma distinto del inglés pasó de 53,8% a 61,2% de los estrenos. Es una lectura de composición dentro de cada año, no de volumen: la muestra tiene 1.000 títulos anuales por diseño.




Figura 8. Los géneros se comparan dentro de cada formato porque la fuente usa vocabularios distintos para series y películas. Aun así el resultado es inequívoco: el género de serie con menos atención supera al mejor género de película.

6. Justificación de las representaciones gráficas seleccionadas

Cada figura se eligió mapeando la naturaleza del dato con la tarea analítica de la audiencia, y no por preferencia estética.

Fig.	Representación	Naturaleza del dato	Tarea analítica	Por qué esta y no otra
F1	Curva de concentración (Lorenz)	Cuantitativa acumulada	Evaluar distribución y desigualdad	Una barra por título sería ilegible con 30.000 casos; la curva muestra la desigualdad en una sola forma
F2	Barras horizontales, small multiples	Categoría × cuantitativa	Comparar dos categorías	Dos magnitudes de escala distinta se separan en dos paneles: un doble eje inventaría una relación inexistente
F3	Barras + línea temporal	Categoría y temporal	Comparar y vigilar evolución	La barra responde «cuánto» y la línea «desde cuándo»; la cohorte 2025 se marca aparte
F4	Dispersión con cuadrantes	Dos variables cuantitativas	Detectar relación y agrupar para decidir	Escala logarítmica por la cola larga; las medianas como umbral generan cuatro acciones distintas
F5	Barras con línea de referencia	Ordinal × cuantitativa	Comparar contra un umbral	La línea del punto de equilibrio convierte el ROI en un juicio inmediato: gana o pierde
F6	Líneas indexadas a base 100	Ordinal × dos cuantitativas	Contrastar dos evoluciones	Indexar a una base común permite un solo eje y hace visible que una serie sube y la otra no
F7	Línea temporal simple	Temporal × proporción	Detectar tendencia	Una sola serie, sin leyenda: el título nombra la variable y los extremos llevan etiqueta
F8	Barras ordenadas, small multiples	Categoría × cuantitativa	Ranking dentro de cada grupo	Un ranking único mezclaría dos taxonomías de género distintas; separarlas evita una comparación falsa

6.1 Atributos visuales y criterios de representación

- **Color funcional, nunca decorativo.** La paleta tiene un solo azul de serie, un gris neutro para «todo lo demás» y un rojo reservado exclusivamente para señalar estado crítico. El rojo nunca identifica una categoría: si aparece, algo está mal.
- **Jerarquía por peso visual.** Cada figura destaca un único dato en color y deja el resto en gris. El tamaño y el contraste son proporcionales a la importancia del dato, no al espacio disponible.
- **Posición y longitud antes que área o ángulo.** No se usan gráficos de torta ni áreas comparadas: el ojo humano compara longitudes con precisión y ángulos mal. La única excepción es la curva de Lorenz, donde el área sombreada refuerza una lectura que la línea ya entrega.
- **Accesibilidad verificada.** La paleta se validó para daltonismo (separación $\Delta E \geq 8$ entre colores adyacentes en simulación deutan y tritan) y la identidad nunca depende sólo del color: toda serie lleva etiqueta directa o tabla equivalente.
- **Señal sobre ruido.** Rejilla de un solo trazo fino, sin bordes en las barras, sin etiquetas en todos los puntos y sin elementos decorativos. Cada píxel renderizado aporta al mensaje o se elimina.
- **Denominador siempre explícito.** Cada figura declara n , la cohorte y la base de cálculo en su subtítulo o pie. Ningún porcentaje aparece sin la población sobre la que se calculó.

7. Desarrollo de la narrativa visual (Data Storytelling)

La narrativa sigue la estructura de cuatro pasos y termina, deliberadamente, en una acción y no en una pregunta retórica.

01 · SITUACIÓN StreamView decide su inversión en contenido por volumen: cuántos títulos suma y a qué costo.	02 · HALLAZGO El 47,5% de la atención está en el 10% de los títulos y el 10,7% del catálogo no registra ninguna interacción. Una serie rinde 3,4 veces más que una película.	03 · IMPLICANCIA US\$ 6,6 mil millones están en el tramo de películas de 1-10 MUSD, donde el 45,7% pierde dinero. Y más presupuesto no mejora la nota ($p = 0,06$).	04 · ACCIÓN Reasignar ese tramo a series con filtro de riesgo, activar las 5.088 joyas ocultas e instalar una puerta de 90 días para todo estreno.
---	--	---	--

El mensaje se adapta a cada audiencia sin cambiar de contenido: el comité recibe el paso 04 primero y la evidencia después; el equipo de programación recibe el dashboard, donde los mismos cuadrantes se vuelven una lista de títulos accionable; finanzas recibe la pestaña de rentabilidad con el detalle por tramo. **Una sola idea central, tres niveles de profundidad.**

8. Diseño e implementación del dashboard interactivo

El dashboard se construyó con **Streamlit** y **Plotly**, sobre el mismo módulo de métricas que alimenta este informe. Se ejecuta con `streamlit run dashboard/app.py`.

8.1 Arquitectura de la interfaz

- **Patrón de lectura Z.** El mensaje principal arriba a la izquierda, la fila de cinco KPIs inmediatamente debajo y el detalle explorable al final. El dato de mayor impacto se ve primero, sin desplazamiento.
- **Un solo panel de filtros.** Año, formato, idioma, género y presencia de señal viven en la barra lateral y gobiernan todas las pestañas. Nunca hay filtros dentro de una tarjeta: así el usuario no puede comparar, sin darse cuenta, dos recortes distintos.
- **Navegación por audiencia.** Cuatro pestañas con niveles de detalle crecientes: visión ejecutiva, diagnóstico de catálogo, rentabilidad, y datos y calidad.
- **La cohorte 2025 viene desactivada por defecto**, con la explicación en el propio control. El usuario puede activarla, pero sabe lo que está haciendo.

8.2 Indicadores clave y mecanismos de interacción

KPI	Qué responde
Títulos en la selección	Tamaño del recorte activo y su peso en el catálogo
Atención en el top 10%	Grado de concentración, con el índice de Gini como apoyo
Catálogo invisible	% y número de títulos sin ninguna interacción
Satisfacción mediana	Nota 0-10 con la base de cálculo declarada
Atención mediana	Rendimiento típico por título del recorte

La interacción disponible incluye filtrado cruzado sobre todas las vistas, navegación por pestañas, información emergente por marca en cada gráfico, zoom y encuadre en los gráficos de Plotly, ordenamiento y paginación de la tabla de detalle, y descarga de la selección filtrada en CSV para continuar el análisis fuera de la herramienta.




Figura 9. Pestaña 1, visión ejecutiva: mensaje, KPIs y las dos visualizaciones que sostienen la recomendación.




Figura 10. Pestaña 2, diagnóstico de catálogo: matriz de cuadrantes título por título, evolución del catálogo invisible y mapa de riesgo y rendimiento por idioma. Los umbrales se recalculan con cada filtro, de modo que el diagnóstico siempre es relativo al recorte que el usuario está mirando.




Figura 11. Pestaña 3, rentabilidad: ROI por tramo, proporción de títulos bajo el punto de equilibrio y dispersión presupuesto-recaudación con la nota codificada en color.

9. Evaluación crítica de la solución desarrollada

9.1 Fortalezas

- **Trazabilidad completa.** Toda cifra del informe, del dashboard y del resumen ejecutivo sale de `src/metricas.py`. No hay números escritos a mano, de modo que el titular de una figura no puede contradecir a la tabla que tiene al lado.
- **Rigor declarado.** Las cuatro trampas del conjunto de datos —el 0 como dato faltante, la nota ausente confundida con nota baja, la muestra balanceada y la cohorte 2025 incompleta— fueron detectadas, documentadas y neutralizadas antes de graficar.
- **Coherencia entre productos.** Informe, dashboard y presentación comparten paleta, tipografía, criterios de titulación y convenciones de medición.
- **Cierre accionable.** El proyecto no termina en un hallazgo sino en cuatro acciones con responsable, métrica de control y plazo.

9.2 Limitaciones

Lo que estos datos no permiten afirmar. La limitación principal es que **no existe telemetría propia de reproducción**. «Atención» es un índice externo de popularidad, no horas vistas; «interacciones» son calificaciones emitidas, no sesiones; y no hay ninguna variable de suscripción, dispositivo ni churn. Por lo tanto el informe describe el rendimiento del **catálogo**, no el comportamiento de los **usuarios**, y ninguna conclusión sobre retención puede sostenerse sólo con esta base.

- **Cobertura financiera parcial.** Sólo el 23,4% de las películas informa presupuesto y recaudación. Las conclusiones de rentabilidad aplican a ese subconjunto y probablemente sobrerrepresentan producciones de circuito comercial.

- **Muestra balanceada.** Con 1.000 títulos por año por diseño, el conjunto no refleja el tamaño real del catálogo en cada período. Es válido para comparar composiciones y tasas; no lo es para estimar volúmenes.
- **Sin fecha real de alta.** `date_added` cae siempre dentro del año de estreno, de modo que no se puede medir antigüedad en catálogo ni velocidad de incorporación.
- **Sesgo de exposición.** La atención observada ya está influida por el propio motor de recomendación: un título con poca atención puede no ser malo, sino no haber sido mostrado. La medida es de resultado, no de calidad intrínseca.
- **Correlación no es causalidad.** Que el presupuesto se asocie a la atención no prueba que la produzca; un presupuesto mayor viene acompañado de más marketing y mayor distribución, que son parte del efecto observado.

9.3 Oportunidades de mejora

- Incorporar telemetría propia —horas vistas, tasa de finalización, altas y bajas por título— para pasar de un proxy de popularidad a una medida real de engagement.
- Añadir una vista de cohortes que siga a cada estreno desde su lanzamiento y permita comparar títulos con la misma madurez.
- Automatizar la actualización del catálogo integrado y publicar el dashboard en un servidor, para que deje de depender de una ejecución local.
- Incorporar el costo de licencia de las series, hoy ausente, para cerrar el análisis de retorno también en el formato que se recomienda priorizar.

10. Conclusiones y recomendaciones

Conclusión. StreamView no tiene un problema de tamaño de catálogo: tiene un problema de asignación. La atención está extremadamente concentrada, el formato serie rinde varias veces más que la película, una parte relevante del catálogo no llega a nadie y el tramo de inversión que más dinero moviliza es el que peor retorno entrega. Todo eso es corregible sin aumentar el presupuesto.

R1 · Reasignar el tramo de películas de 1 a 10 millones de dólares

Trasladar progresivamente ese tramo —US\$ 6,6 mil millones acumulados en 1.196 títulos de la cohorte 2010–2024, con ROI mediano 1,20— hacia producción de series, priorizando los idiomas de alto rendimiento y bajo riesgo identificados en el dashboard.

Responsable: Dirección de Contenidos · **Plazo:** presupuesto 2026 · **Métrica de control:** atención mediana de la cartera de estrenos ≥ 25 a los doce meses.

R2 · Activar las 5.088 joyas ocultas antes de comprar contenido nuevo

Son títulos con nota sobre la mediana y atención bajo la mediana: ya están pagados y ya gustan. Priorizarlos en el motor de recomendación y en campañas de CRM tiene costo marginal frente a una adquisición.

Responsable: Programación + CRM · **Plazo:** seis meses · **Métrica de control:** 1.500 de esos títulos por sobre la mediana de atención.

R3 · Instalar una puerta de 90 días para todo estreno

Todo título que a los noventa días no registre interacciones entra automáticamente a revisión: se refuerza su promoción o se evalúa su retiro. Hoy 3.202 títulos (10,7% del catálogo) están en esa condición sin que nadie lo revise.

Responsable: Programación · **Plazo:** doce meses · **Métrica de control:** catálogo invisible bajo el 6%.

R4 · Instrumentar telemetría propia de reproducción

Registrar horas vistas, tasa de finalización y bajas atribuibles por título. Es la condición para que las tres recomendaciones anteriores se puedan verificar con datos propios y no con un proxy externo de popularidad.

Responsable: Ingeniería de Datos · **Plazo:** un trimestre · **Métrica de control:** 100% de los estrenos con telemetría desde el día uno.

Qué no recomendamos. No recomendamos ampliar el catálogo ni subir el presupuesto medio de las películas. La evidencia muestra que ese gasto compra visibilidad pero no satisfacción ($p = 0,06$), y que el tramo donde más se concentra es el único donde casi la mitad de los títulos pierde dinero.

Declaración de uso de inteligencia artificial

En conformidad con la normativa de la asignatura, el equipo declara el uso de herramientas de inteligencia artificial generativa durante el desarrollo de este encargo.

Herramienta	Uso dado	Verificación y responsabilidad
Claude (Anthropic)	Apoyo en la exploración del conjunto de datos, revisión crítica de decisiones de diseño visual, redacción y ordenamiento del informe, y depuración del código del dashboard.	Todo el análisis fue verificado ejecutando el código sobre los datos originales. Las cifras del informe se generan desde el propio conjunto de datos, no desde la herramienta. La definición del problema, la selección de hallazgos y las recomendaciones finales son del equipo.

El equipo asume la responsabilidad íntegra por el contenido, las cifras y las conclusiones presentadas. Ninguna cifra de este documento proviene de una estimación del modelo: todas se calculan en `src/metricas.py` a partir de los archivos entregados por la organización, y pueden reproducirse ejecutando el proyecto.

Anexo A · Diccionario de variables del catálogo integrado

Variable	Naturaleza	Descripción	Origen
id_titulo	texto	Identificador único (formato + show_id de origen)	Derivada
formato	categorica	Película o Serie	Ambas fuentes
titulo	texto	Nombre del contenido	Ambas fuentes
anio	temporal	Año de estreno (2010-2025)	release_year
fecha_referencia	temporal	Fecha dentro del año de estreno. NO es la fecha de alta en catálogo	date_added
pais_principal	categorica	Primer país listado en la coproducción	country
idioma_original	categorica	Código ISO del idioma original	language
bloque_idioma	categorica	Inglés / No inglés	Derivada
genero_principal	categorica	Primer género declarado	genres
segmento	categorica	Formato × bloque de idioma: unidad de decisión presupuestaria	Derivada
atencion	cuantitativa continua	Índice de popularidad (proxy de interés/engagement)	popularity
interacciones	cuantitativa discreta	Nº de calificaciones emitidas por la audiencia	vote_count
satisfaccion	cuantitativa continua	Nota media 0-10. Nula si no hay interacciones	vote_average
sin_senal	booleana	True si el título no registra ninguna interacción	Derivada
budget	cuantitativa continua	Presupuesto en USD. Sólo películas. 0 → nulo	budget
revenue	cuantitativa continua	Recaudación en USD. Sólo películas. 0 → nulo	revenue
roi	cuantitativa continua	revenue / budget. 1,0 = punto de equilibrio	Derivada
cohortes_maduras	booleana	True para 2010-2024. 2025 se excluye de tendencias	Derivada
muestra_balanceada	booleana	Marca que el conjunto tiene 1.000 títulos por año por diseño	Derivada

Anexo B · Estructura del proyecto y reproducción

EPI_StreamView_Analytics/ └─ README.md └─ requirements.txt └─ .streamlit/config.toml └─ data/	Instrucciones de instalación y ejecución Dependencias con versión y notas de compatibilidad Tema del dashboard (misma identidad visual)
---	---

		raw/	Los dos CSV originales, sin modificar
		└ processed/	Catálogo integrado, diccionario, auditoría y tablas
		notebooks/	
		└ 01_analisis_exploratorio.ipynb	
		src/	
		└ config.py	Rutas, paleta validada y estilo compartido
		└ etl.py	Integración y saneamiento documentado
		└ metricas.py	Todos los indicadores del proyecto
		└ graficos.py	Las ocho figuras del informe
		└ documentos.py	Generación del informe y del resumen en PDF
		└ construir_notebook.py	Construcción y ejecución del cuaderno
		dashboard/	
		└ app.py	Dashboard interactivo (Streamlit + Plotly)
		images/	Figuras y capturas generadas
		docs/	Informe ejecutivo y resumen ejecutivo (PDF y HTML)

```
pip install -r requirements.txt
```

```
python src/etl.py           # integra y sanea las dos fuentes
python src/metricas.py      # calcula indicadores y tablas agregadas
python src/graficos.py      # genera las ocho figuras del informe
python src/documentos.py    # arma el informe y el resumen en PDF
python src/construir_notebook.py # arma y ejecuta el cuaderno

streamlit run dashboard/app.py # levanta el dashboard interactivo
```

El proyecto se ejecuta de principio a fin sin modificaciones adicionales: los datos originales están incluidos en `data/raw/` y cada script escribe su salida en la carpeta correspondiente.